

基于端侧大模型的长文档审阅工作台研究

摘要：本文提出一种隐私优先的端侧长文档审阅工作台，采用三级自适应路由机制，将轻量问答、链式推理与跨文档审阅任务分别调度至不同规格的本地模型，实现毫秒级首字响应与深度审阅的平衡。系统引入字符级滑窗溯源校验，对模型回答逐句回查原文，未溯源句自动标注提示人工复核，有效抑制端侧场景下的幻觉问题。

关键词：端侧大模型；长文档审阅；自适应路由；溯源校验

1 引言

随着开源模型能力提升，本地部署的隐私计算方案逐渐可行。然而长文档场景下，单一模型难以兼顾速度与深度，本文通过双模型架构与智能降级策略解决这一矛盾。

2 方法

2.1 三级自适应路由

路由器基于问题复杂度特征（关键词、长度、跨文档指代）将请求调度至 1.7B 快答档或 4B 审阅档，并在深档超时时自动降级补发，保障响应可用性。

2.2 溯源校验

构建字符级 8-gram 索引，对回答逐句滑窗匹配原文，命中率低于阈值的句子标记为未溯源。校验纯 CPU 毫秒级，零额外推理开销。

3 实验设置

baseline 为单模型直答方案，评测指标包括首字时延、总时延、token 吞吐与溯源命中率。测试集为三份真实合同的脱敏样例，覆盖试用期、违约金、质保等高频条款。